# МГТУ им. Н. Э. Баумана, кафедра ИУ5 курс "Технологии машинного обучения"

# Лабораторная работа №5

«Линейные модели, SVM и деревья решений»

ВЫПОЛНИЛ:

Пученков Д.О.

Группа: ИУ5-61Б

ПРОВЕРИЛ:

Гапанюк Ю.Е.

**Цель лабораторной работы:** изучение линейных моделей, SVM и деревьев решений.

#### Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
  - одну из линейных моделей;
  - SVM;
  - дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

### Выполненная работа:

В данной работе модели будут строиться для решения задачи классификации. Загрузка и первичный анализ данных. Формирование DataFrame:

```
In [2]: wine = load_wine()
In [3]: # Cφορмируем DataFrame
         wine_df = pd.DataFrame(data= np.c_[wine['data'], wine['target']],
                               columns= list(wine['feature_names']) + ['target'])
In [4]: wine_df.isnull().sum()
Out[4]: alcohol
         malic_acid
         ash
         alcalinity_of_ash
         magnesium
         total_phenols
         flavanoids
         nonflavanoid_phenols
         proanthocyanins
         color_intensity
        hue
         od280/od315_of_diluted_wines
         proline
         target
         dtype: int64
In [5]: wine_df.head
                                           alcohol malic_acid ash alcalinity_of_ash magnesium total_phenols \
Out[5]: <bound method NDFrame.head of
                                               15.6 127.0
11.2 100.0
             14.23 1.71 2.43
13.20 1.78 2.14
                                                                     100.0
                                                                                      2.65
              13.16 2.36 2.67
14.37 1.95 2.50
13.24 2.59 2.87
                                                         18.6
                                                                     101.0
                                                                                      2.80
                                                        16.8
21.0
                                                                     113.0
                                                                                      3.85
        173 13.71
174 13.40
175 13.27
176 13.17
177 14.13
                        5.65 2.45 20.5
3.91 2.48 23.0
4.28 2.26 20.0
2.59 2.37 20.0
4.10 2.74 24.5
                                                                      95.0
                                                                                      1.68
                                                                    95.0
102.0
120.0
                                                                                      1.80
                                                                                      1.59
                                                                     120.0
                                                                                      1.65
```

Разделение данных на обучающую и тестовую выборки. Построение модели «Логистическая регрессия»:

```
In [6]: def convert_target_to_binary(array:np.ndarray, target:int) -> np.ndarray:
          # Если целевой признак совпадает с указанным, то 1 иначе
              res = [1 if x==target else 0 for x in array]
              return res
 In [7]: bin_wine_y = convert_target_to_binary(wine.target, 2)
 In [8]: wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
              wine.data, bin_wine_y, test_size=0.2, random_state=1)
 In [9]: cl1 = LogisticRegression()
In [10]: cl1.fit(wine X train, wine v train)
          onverge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
          Increase the number of iterations (max_iter) or scale the data as shown in:
          https://scikit-learn.org/stable/modules/preprocessing.html Please also refer to the documentation for alternative solver options:
            https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
extra_warning_msg=_LOGISTIC_SOLVER_CONVERGENCE_MSG)
Out[10]: LogisticRegression(C=1.0, class_weight=None, dual=False, fit_intercept=True,
                              intercept_scaling=1, l1_ratio=None, max_iter=100,
multi_class='auto', n_jobs=None, penalty='l2',
random_state=None, solver='lbfgs', tol=0.0001, verbose=0,
                              warm_start=False)
In [11]: pred wine y test = cl1.predict(wine X test)
          pred_wine_y_test
In [12]: pred_wine_y_test_proba = cl1.predict_proba(wine_X_test)
          pred_wine_y_test_proba[:10]
Out[12]: array([[6.67502815e-02, 9.33249719e-01],
                  [9.99028518e-01, 9.71481719e-04],
                  [9.98580105e-01, 1.41989547e-03],
[9.99003483e-01, 9.96517066e-04],
                  [9.88929037e-01, 1.10709626e-02], [4.53547396e-02, 9.54645260e-01],
                  [9.54959671e-01, 4.50403288e-02],
                  [9.98955423e-01, 1.04457706e-03],
[7.08307657e-03, 9.92916923e-01],
                  [9.68840217e-01, 3.11597833e-02]])
In [13]: # Βεροяπность принадлежности κ θ κлассу [round(x, 4) for x in pred_wine_y_test_proba[:10,0]]
Out[13]: [0.0668, 0.999, 0.9986, 0.999, 0.9889, 0.0454, 0.955, 0.999, 0.0071, 0.9688]
In [14]: # Вероятность принадлежности к 1 классу
          [round(x, 4) for x in pred_wine_y_test_proba[:10,1]]
Out[14]: [0.9332, 0.001, 0.0014, 0.001, 0.0111, 0.9546, 0.045, 0.001, 0.9929, 0.0312]
In [15]: # Сумма вероятностей равна 1
          pred_wine_y_test_proba[:10,0] + pred_wine_y_test_proba[:10,1]
Out[15]: array([1., 1., 1., 1., 1., 1., 1., 1., 1.])
In [16]: accuracy_score(wine_y_test, pred_wine_y_test)
Out[16]: 0.97222222222222
```

#### Построение модели «SVC»:

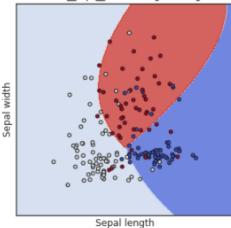
```
def plot_contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.
       ax: matplotlib axes object
      clf: a classifier
xx: meshgrid ndarray
       params: dictionary of params to pass to contourf, optional
      Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
      Z = Z.reshape(xx.shape)
#Можно проверить все ли метки классов предсказываются
       #print(np.unique(Z))
       out = ax.contourf(xx, yy, Z, **params)
      return out
def plot_cl(clf):
    title = clf._repr_
    clf.fit(wine_X, wine_y)
    fig, ax = plt.subplots(figsize=(5,5))
    X0, X1 = wine_X[:, 0], wine_X[:, 1]
      xx, yy = make_meshgrid(X0, X1)
plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
ax.scatter(X0, X1, c=wine_y, cmap=plt.cm.coolwarm, s=20, edgecolors='k')
      ax.set_ylim(yx.min(), xx.max())
ax.set_ylim(yy.min(), yy.max())
ax.set_ylabel('Sepal length')
ax.set_ylabel('Sepal width')
       ax.set_xticks(())
       ax.set_yticks(()
       ax.set_title(title)
      plt.show()
```

## Построение модели «Дерево решений»:

```
wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
    wine.data, wine.target, test_size=0.2, random_state=1)
```

```
plot_cl(SVC(kernel='poly', degree=2, gamma=0.2, C=1.0))
```

<br/><bound method BaseEstimator.\_\_repr\_\_ of SVC(degree=2, gamma=0.2, kernel='poly')>

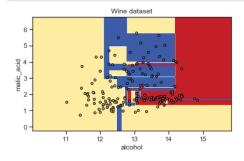


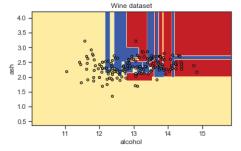
svc = SVC(kernel='poly', degree=2, gamma=0.4, C=1.2).fit(wine\_X\_train, wine\_y\_train)
target\_svc = svc.predict(wine\_X\_test)

accuracy\_score(wine\_y\_test, target\_svc)

#### 0.972222222222222

In [26]: plot\_tree\_classification('Wine dataset', wine)





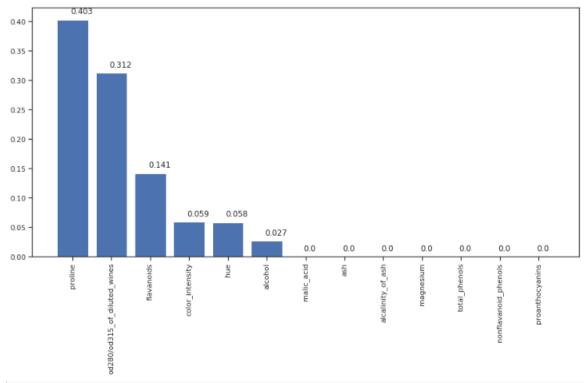
```
wine_x_ds = pd.DataFrame(data=wine['data'], columns=wine['feature_names'])
wine_x_ds.head()
```

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocya
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82

```
# Обучим дерево на всех признаках wine
wine_tree_cl = DecisionTreeClassifier(random_state=2)
wine_tree_cl.fit(wine_x_ds, wine.target)
wine_tree_cl
```

DecisionTreeClassifier(random\_state=2)

```
In [29]: # Важность признаков
            list(zip(wine_x_ds.columns.values, wine_tree_cl.feature_importances_))
Out[29]: [('alcohol', 0.012570564071187309),
                'malic_acid', 0.014223159778821876),
              ("ash', 0.0),
('aslalinity_of_ash', 0.0),
('magnesium', 0.0534597951279922),
('total_phenols', 0.0),
('flavanoids', 0.16704836491408806),
               ('nonflavanoid_phenols', 0.0),
             ('proanthocyanins', 0.0),
('color_intensity', 0.0),
('hue', 0.058185091460406506),
('od280/od315_of_diluted_wines', 0.3120425747831769),
('proline', 0.38247044986432716)]
In [30]: # Важность признаков в сумме дает единицу
            sum(wine_tree_cl.feature_importances_)
Out[30]: 1.0
In [31]: from operator import itemgetter
            def draw_feature_importances(tree_model, X_dataset, figsize=(15,7)):
                 Вывод важности признаков в виде графика
                  # Сортировка значений важности признаков по убыванию
                 list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
                  # Названия признаков
                 labels = [x for x,_ in sorted_list]
# Важности признаков
                  data = [x for _,x in sorted_list]
                  # Вывод графика
fig, ax = plt.subplots(figsize=figsize)
                  ind = np.arange(len(labels))
                  plt.bar(ind, data)
plt.xticks(ind, labels, rotation='vertical')
                   .
# Вывод значений
                  for a,b in zip(ind, data):
                      plt.text(a-0.05, b+0.01, str(round(b,3)))
                  plt.show()
return labels, data
```



# Список признаков, отсортированный на основе важности, и значения важности wine\_tree\_cl\_fl, wine\_tree\_cl\_fd

```
(['proline',
  'od280/od315_of_diluted_wines',
  'flavanoids',
  'color_intensity',
 'hue',
  'alcohol',
  'malic_acid',
  'ash',
  'alcalinity_of_ash',
 'magnesium',
  'total_phenols',
  'nonflavanoid_phenols',
  'proanthocyanins'],
 [0.4029517999458307,
 0.3120425747831769,
 0.1414466773122087,
 0.058580132648368075,
 0.058185091460406506,
 0.026793723850009183,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0])
```

In [34]: wine x ds.head() Out[34]: alcohol malic\_acid ash alcalinity\_of\_ash magnesium total\_phenols flavanoids nonflavanoid\_phenols proanthocyanins color\_intensity hue od280/od31 0 14.23 1.71 2.43 2.80 15.6 127.0 3.06 0.28 2.29 5.64 1.04 **1** 13.20 1.78 2.14 11.2 100.0 2.65 2.76 0.26 1.28 4.38 1.05 18.6 2 13.16 2.36 2.67 101.0 2.80 3.24 0.30 2.81 5.68 1.03 14.37 1.95 2.50 16.8 113.0 3.85 3.49 0.24 2.18 7.80 0.86 **4** 13.24 2.59 2.87 21.0 118.0 2.80 2.69 0.39 1.82 4.32 1.04 In [35]: # Пересортируем признаки на основе важности wine\_x\_ds\_sorted = wine\_x\_ds[wine\_tree\_cl\_fl] wine\_x\_ds\_sorted.head() Out[35]: proline od280/od315\_of\_diluted\_wines flavanoids hue magnesium malic\_acid alcohol ash alcalinity\_of\_ash total\_phenols nonflavanoid\_phenols 0 1065.0 3.06 1.04 127.0 1.71 14.23 2.43 15.6 2.80 0.28 1 1050.0 3.40 2.76 1.05 100.0 1.78 13.20 2.14 11.2 2.65 0.26 2 1185.0 3.17 3.24 1.03 101.0 2.36 13.16 2.67 18.6 2.80 0.30 3 1480.0 3.45 3.49 0.86 113.0 1.95 14.37 2.50 16.8 3.85 0.24 4 735.0 2.93 2.69 1.04 118.0 2.59 13.24 2.87 21.0 2.80 0.39 4 In [36]: # Разделим выборку на обучающую и тестовую wine\_X\_train, wine\_X\_test, wine\_y\_train, wine\_y\_test = train\_test\_split(
 wine\_x\_ds\_sorted, wine.target, test\_size=0.5, random\_state=1) wine\_X\_train.shape, wine\_X\_test.shape Out[36]: ((89, 13), (89, 13)) In [37]: # Обучим дерево и предскажем результаты на всех признаках wine\_tree\_cl\_feat\_1 = DecisionTreeClassifier(random\_state=1).fit(wine\_X\_train, wine\_y\_train)
wine\_y\_test\_predict = wine\_tree\_cl\_feat\_1.predict(wine\_X\_test) wine\_y\_test\_predict.shape Out[37]: (89,) # Проверим точность по классам print\_accuracy\_score\_for\_classes(wine\_y\_test, wine\_y\_test\_predict) Метка Accuracy 0 0.78787878787878 0.7941176470588235 1 0.9545454545454546 2